Centro Universitário de Excelência
Sistemas de Informação

MecaniQA Cloud

OAT 2: Monitorando a Continuidade

Observabilidade, alertas e autoscaling no Kubernetes

Autor: Artur Maia Coqueiro
Douglas Renan Santos
Kayky Ribeiro Souza
Lenilson Dias Soares
Joab Nascimento Rodrigues

Vitória da Conquista, 2026

Agenda

1. Arquitetura
Simulador IoT, Prometheus e Grafana

2. Painéis e alertas
CPU, memória, erros e sucessos

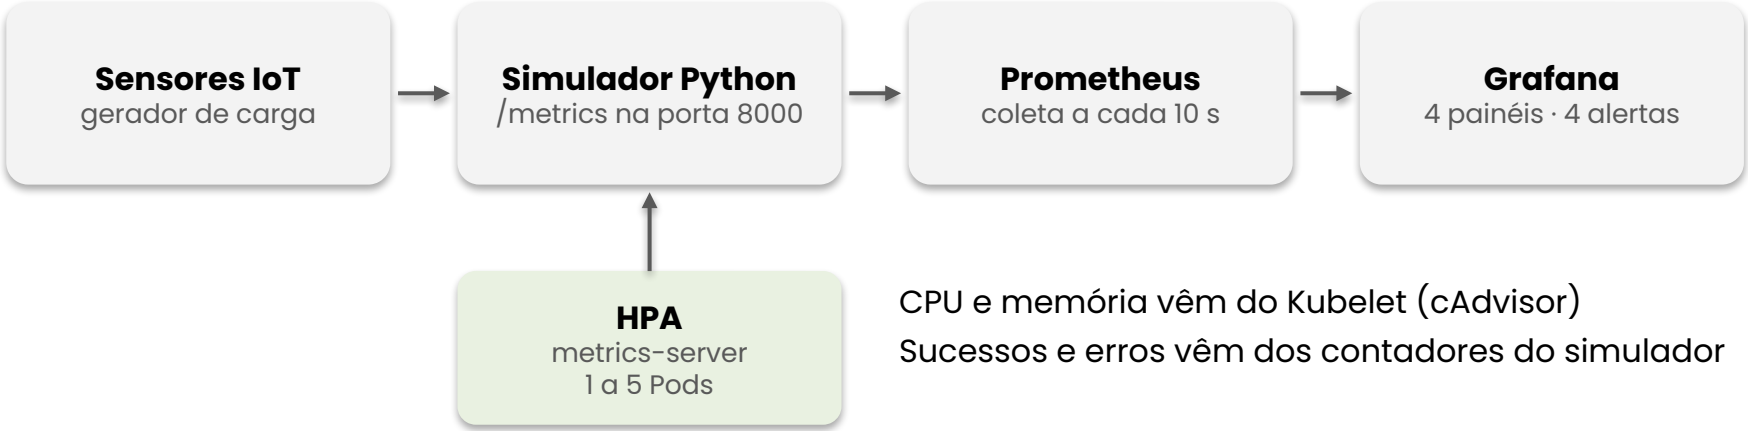
3. Autoscaling
HPA e teste de estresse

4. Evidências
Painéis durante a carga

5. Continuidade
SLA, SLO, RTO, RPO e runbooks

Objetivo
Dar visibilidade ao cluster e escalar a ingestão IoT nos horários de pico

Arquitetura de monitoramento



CPU e memória vêm do Kubelet (cAdvisor)
Sucessos e erros vêm dos contadores do simulador

Tudo no namespace mecaniqa, com manifestos versionados em k8s/oat2

Fonte: k8s/oat2 (iot.yaml, prometheus.yaml, grafana.yaml, hpa.yaml)

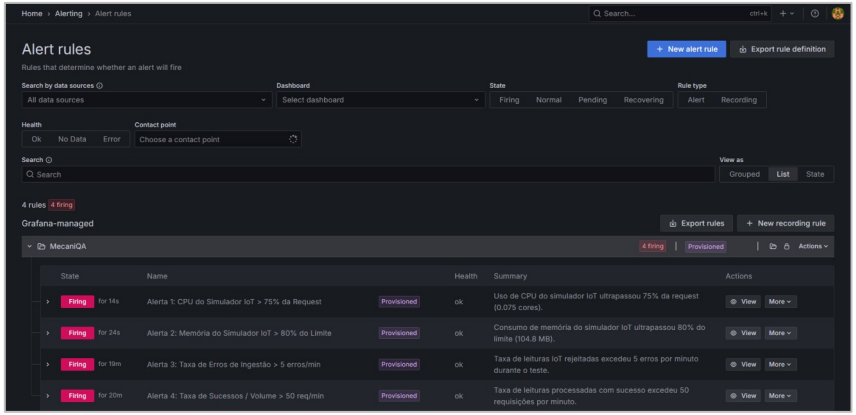
Painéis e alertas

Um painel e uma regra de alerta para cada sinal

Sinal	Origem	Alerta dispara
CPU	Kubelet / cAdvisor	> 75% da request
Memória	Kubelet / cAdvisor	> 100 MiB
Erros	Simulador	> 5 rejeições/min
Sucessos	Simulador	> 50 leituras/min

4 regras em Firing durante a carga

Cada regra espera 30 s acima do limiar



Fonte: k8s/oat2/dashboards · k8s/oat2/grafana-alerting.yaml · Grafana › Alert rules

HPA e teste de estresse

262.544
requisições em 180 s

~1.440/s
vazão média

1 → 5
Pods em ~45 s

0
reinícios ou OOMKilled

```
PS> kubectl get hpa -n mecaniqa
NAME              REFERENCE                TARGETS                        MINPODS   MAXPODS   REPLICAS   AGE
mecaniqa-iot-hpa   Deployment/mecaniqa-iot   cpu: 238%/60%, memory: 30%/70%   1         5         5          28m

PS> kubectl get pods -n mecaniqa -l app=mecaniqa-iot -o wide
NAME                          READY   STATUS    RESTARTS   AGE   IP           NODE                   NOMINATED NODE   READINESS GATES
mecaniqa-iot-5fcbf7fcf8-2gmhx   1/1     Running   0          11m   10.244.0.17   desktop-control-plane   <none>           <none>
mecaniqa-iot-5fcbf7fcf8-9bxj4   1/1     Running   0          11m   10.244.0.18   desktop-control-plane   <none>           <none>
mecaniqa-iot-5fcbf7fcf8-gr5bb   1/1     Running   0          16m   10.244.0.13   desktop-control-plane   <none>           <none>
mecaniqa-iot-5fcbf7fcf8-l7qnz   1/1     Running   0          47s   10.244.0.22   desktop-control-plane   <none>           <none>
mecaniqa-iot-5fcbf7fcf8-pm5hb   1/1     Running   0          47s   10.244.0.23   desktop-control-plane   <none>           <none>

PS> kubectl top pods -n mecaniqa -l app=mecaniqa-iot
NAME                          CPU(cores)   MEMORY(bytes)
mecaniqa-iot-5fcbf7fcf8-2gmhx   244m         19Mi
mecaniqa-iot-5fcbf7fcf8-9bxj4   240m         19Mi
mecaniqa-iot-5fcbf7fcf8-gr5bb   236m         20Mi
mecaniqa-iot-5fcbf7fcf8-l7qnz   235m         19Mi
mecaniqa-iot-5fcbf7fcf8-pm5hb   236m         19Mi

PS> kubectl describe hpa mecaniqa-iot-hpa -n mecaniqa  (eventos)
Events:
Type     Reason             Age                From                       Message
----     ------             ----               ----                       -------
Warning  FailedUpdateStatus  26m                horizontal-pod-autoscaler  etcdserver: request timed out
Normal   SuccessfulRescale   16m                horizontal-pod-autoscaler  New size: 3; reason: cpu resource utilization (percentage of request) above target
Normal   SuccessfulRescale   94s (x2 over 12m)  horizontal-pod-autoscaler  New size: 3; reason: All metrics below target
Normal   SuccessfulRescale   48s (x3 over 16m)  horizontal-pod-autoscaler  New size: 5; reason: cpu resource utilization (percentage of request) above target
```

Configuração
1 a 5 Pods
CPU 60% · memória 70%

Carga
60 threads · 180 s
20% de leituras inválidas

Escalou sem intervenção manual e reduziu após a carga

Fonte: k8s/oat2/hpa.yaml · kubectl get hpa, top pods e eventos SuccessfulRescale

Painéis durante a carga

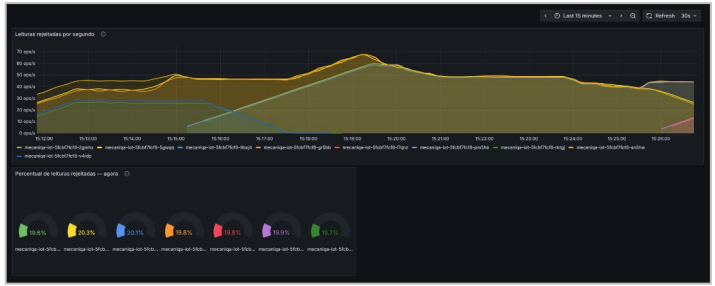
CPU dos Pods



Memória dos Pods



Erros (leituras rejeitadas)



Sucessos (leituras aceitas)



Fonte: dashboards MecaniQA no Grafana durante o teste de estresse

Continuidade e runbooks

Sigla	Meta proposta
SLA	99,9% ao mês (≈ 43 min fora)
SLO	99,95% de /health com HTTP 200
SLI	/health 200 e taxa de leituras aceitas
RTO	15 min para voltar a receber leituras
RPO	Até 24 h do histórico de métricas

Alerta	Primeiro passo do runbook
CPU	kubectl get hpa; se 5/5, elevar o máximo
Memória	kubectl top pods; checar OOMKilled
Erros	kubectl logs; achar o payload inválido
Sucessos	Comparar com os picos de 8h e 17h

Monitoramento, alertas e HPA reagiram sem intervenção manual

Metas da equipe: o teste local não comprova os 99,9% de produção; PVC não é backup

Fonte: docs/oat2 (registros das sessões) · k8s/oat2/grafana-alerting.yaml

Referências

Código, manifestos e evidências

k8s/oat2 · scripts · docs/evidencias · github.com/LenilsonSoares/mecaniQA-nuvem-macapa

Documentação oficial

Kubernetes: kubernetes.io/docs/tasks/run-application/horizontal-pod-autoscale

Prometheus: prometheus.io/docs · Grafana Alerting: grafana.com/docs/grafana/latest/alerting

Material da disciplina

OAT 2: Monitorando a Continuidade · Caderno de Guias